

# Création d'un compte Azure

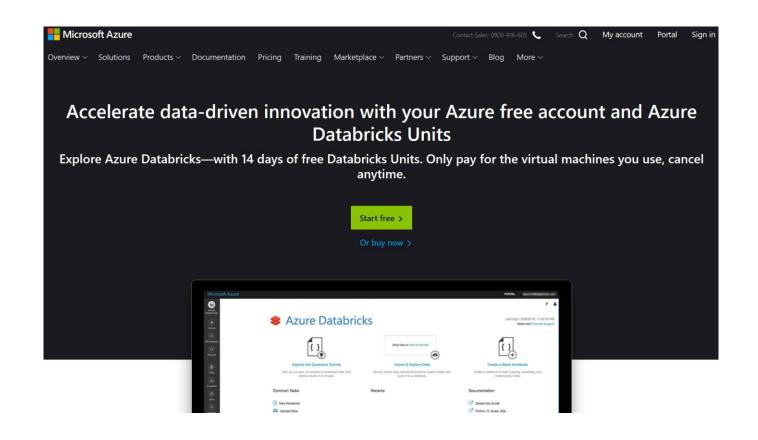
#### **Azure Databricks**

Already using Azure? try Azure

Databricks now or

create a <u>free Azure account to</u> <u>start using Azure Databricks</u>

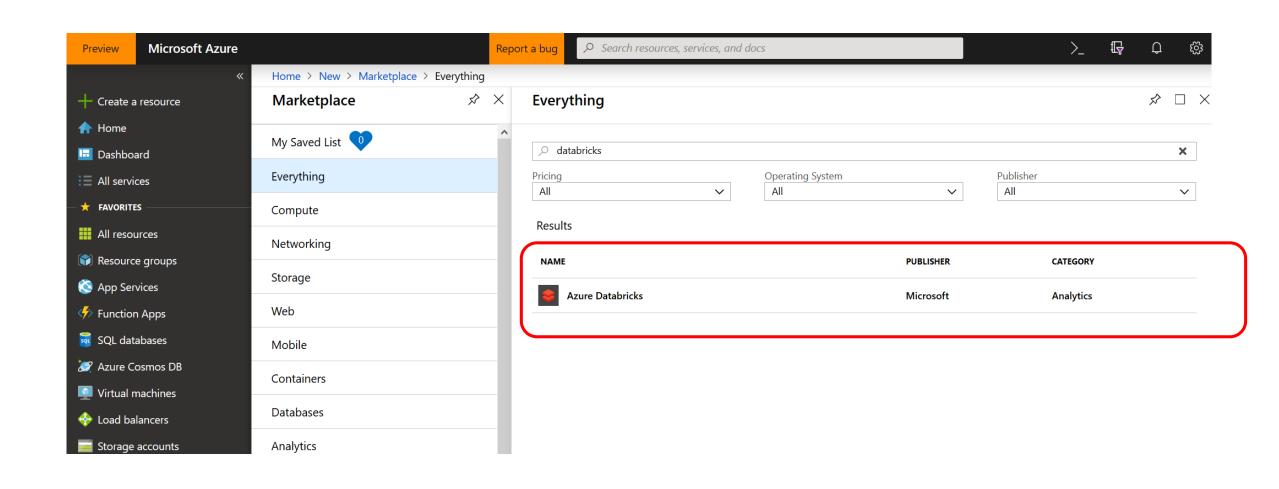
https://azure.microsoft.com/enus/free/services/databricks/



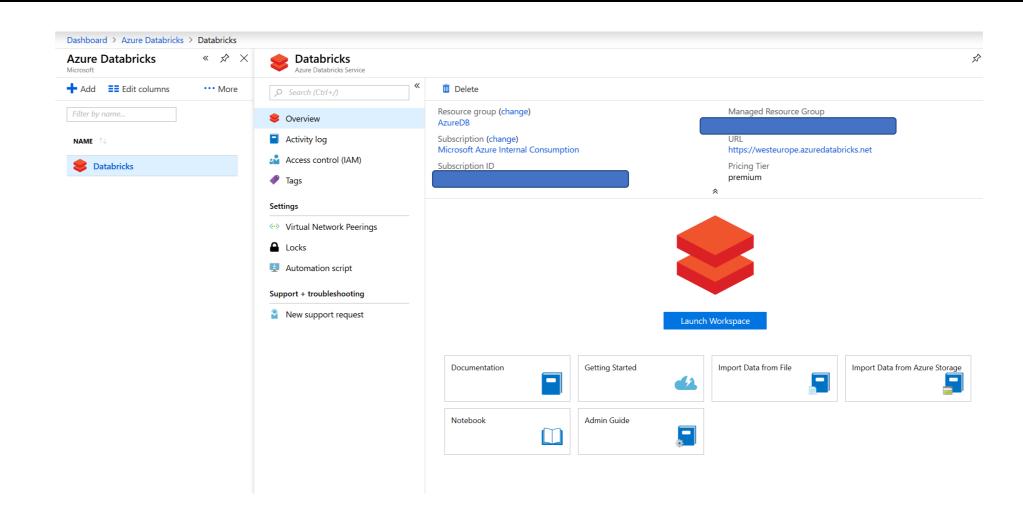


# Provisionnement service Azure Databricks

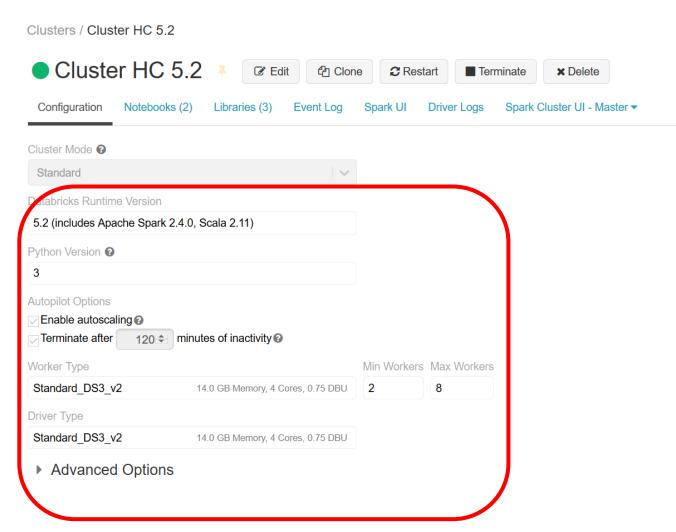
#### 1. Création du service Azure Databricks



#### 1. Création du service Azure Databricks



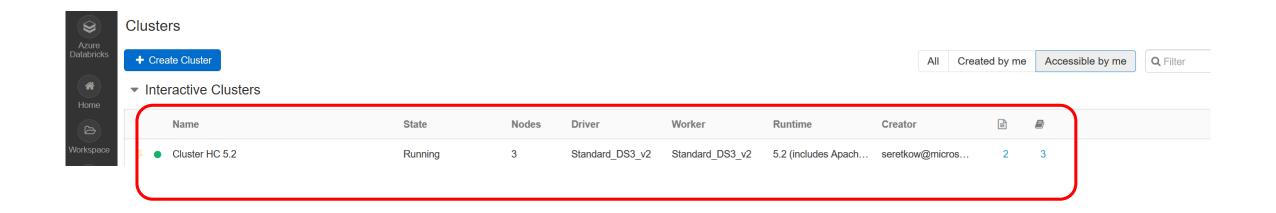
#### 2. Création du Cluster Spark Databricks



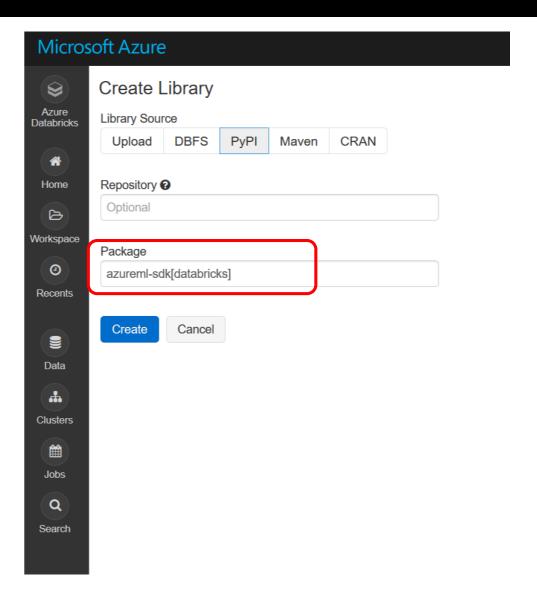
Bien vérifier que les options *Enable* autoscaling et *Terminate after X minutes of activity* soient activées.

Cela permet de mettre en place *l'autoscaling* entre les *workers* du cluster Spark et de désactiver automatiquement le cluster en cas d'inactivité spécifiée par un timeout.

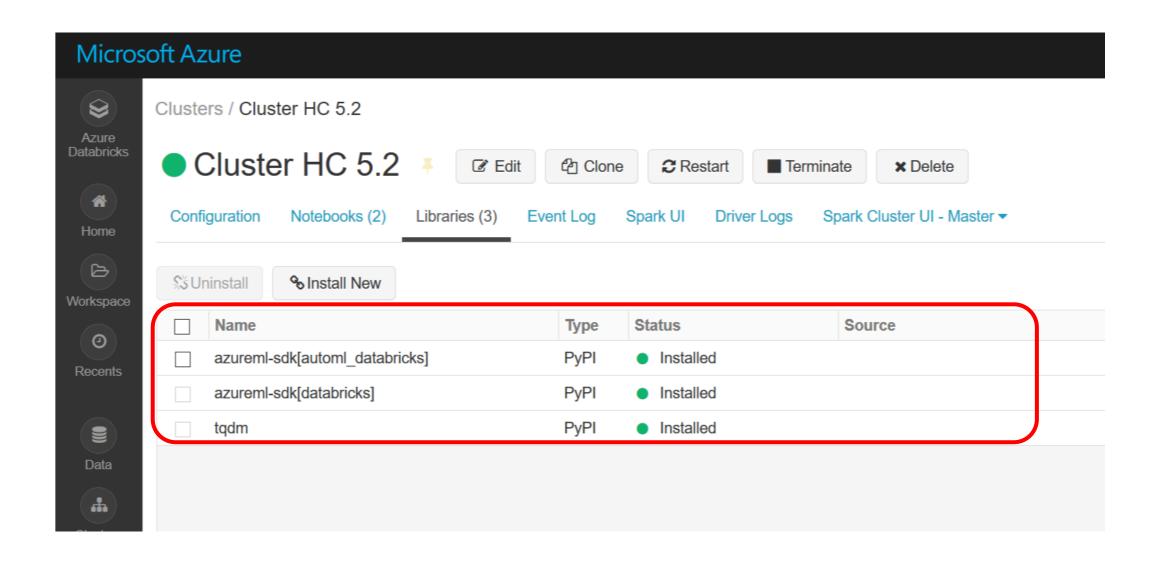
#### 2. Création du Cluster Spark Databricks

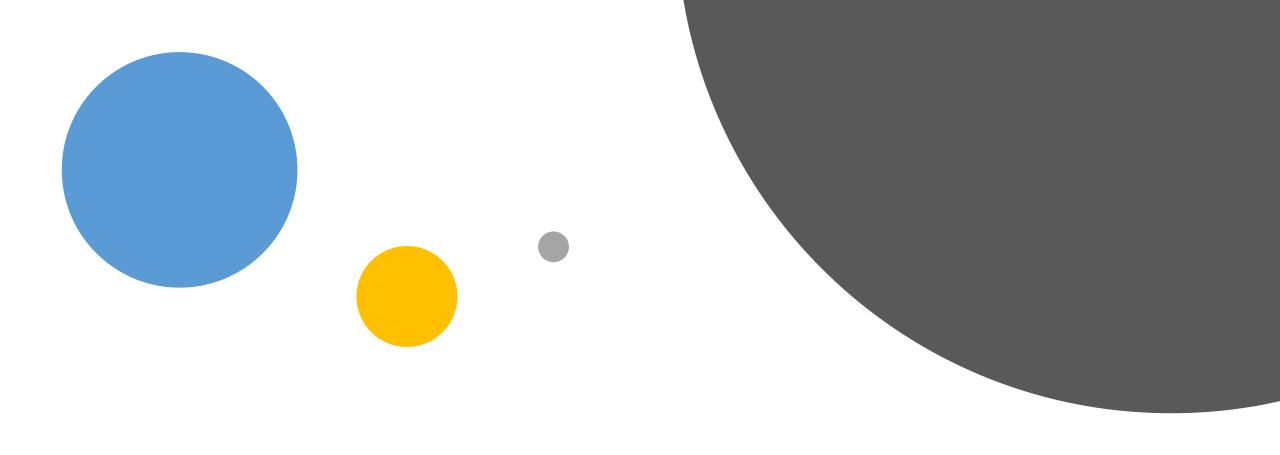


#### 3. Importation des librairies Azure ML service dans Databricks



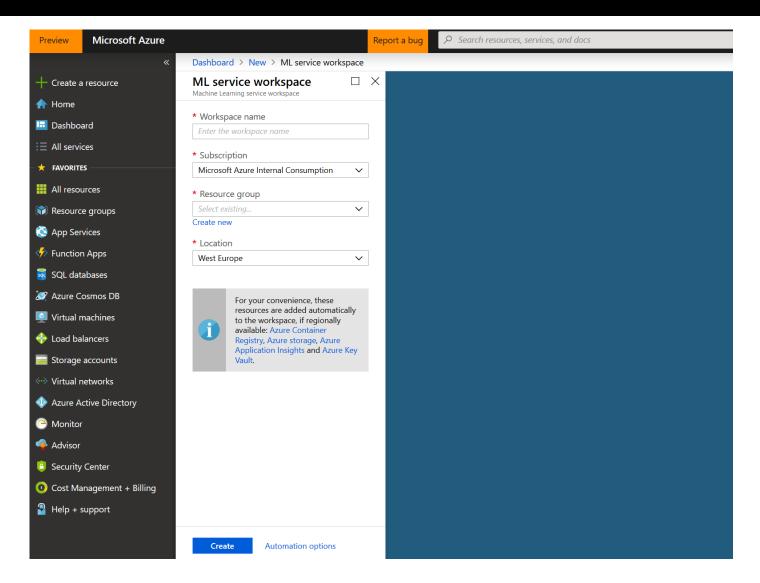
#### 4. Association des librairies Azure ML service au cluster Databricks





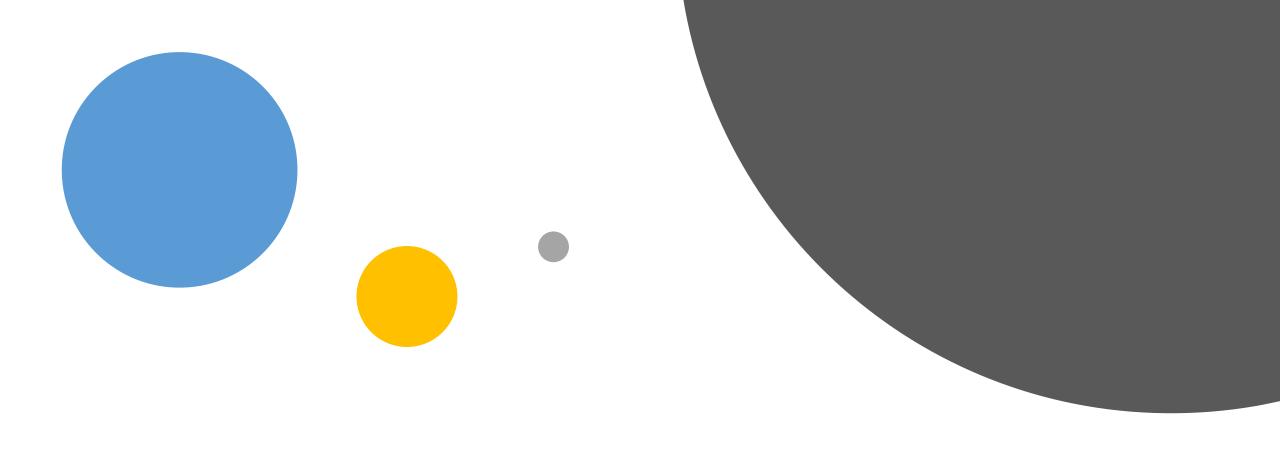
## Provisionnement Azure ML service

#### 5. Provisionnement du service Azure ML service



Une fois le service provisionné il sera nécessaire de retenir le nom du workspace, la localisation, le ressource groupe ainsi que l'ID du service.

Ces valeurs seront nécessaires pour assurer une connexion au workspace Azure ML service depuis un notebook Azure Databricks.




### Exercices du lab

#### **Exercices**

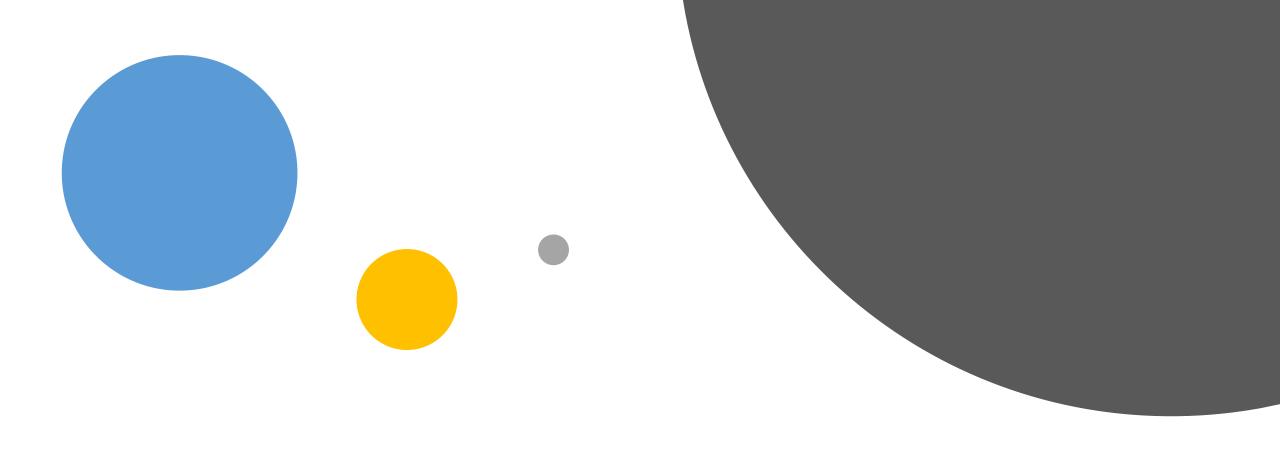
Notebooks & données

Les données sont dans Data.zip

Le Fichier .DBC est une archive Databricks qui contient tous les notebooks.



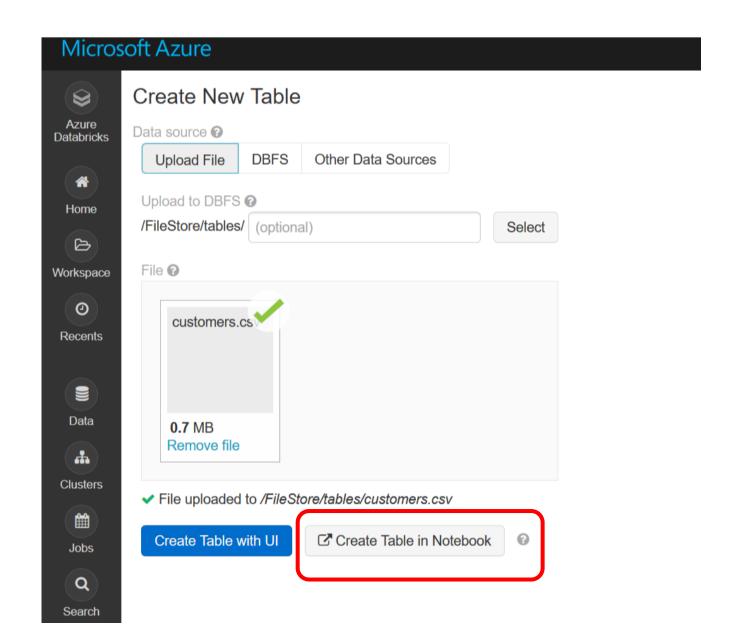
https://github.com/retkowsky/Cloud Workshop AzureDatabricks



## Chargement des données

## Chargement des données

- 1. Télécharger le fichier Data.zip
- 2. Dézipper ce fichier sur votre poste de travail pour extraire les différents fichiers .CSV
- 3. Charger chaque fichier .CSV dans DBFS (Databricks File System) à l'aide de l'assistant suivant et cliquer ensuite sur *Create Table in Notebook* pour visualiser le code Python correspondant.



#### 6. Chargement des données

Remplacer les valeurs initiales *false* par *true* du code Python pour inférer automatiquement les propriétés des variables et récupérer le nom de chaque variable en première ligne.

Un *dataframe* est ainsi créé.

